L’impact du renommage sur les métriques de procédés

Pierre Chanson

Encadrants: Jean-Rémy Falleri et Matthieu Foucault

Plan

- Contexte, gestionnaire de versions, domaine de recherche, métriques et renommage
- Problématique du stage
- Deux Expérimentations, méthodologie
- Résultats
- Conclusion et recommandations aux développeurs et chercheurs

Contexte **définition du sujet**

- Les gestionnaires de versions (VCS)
- La prédiction de bugs
- Les métriques*

** Bird et al. "Don't touch my code ! : examining the effects of ownership on software quality", ESEC/FSE 2011.*

** Nagappan et al. "Use of relative code churn measures to predict system defect density", ICSE 2005.*

Contexte **métriques et procédés***

- NoD (Number of Developers): nombre de développeurs
- NoC (Number of Changes): nombre de modifications
- CC (Code Churn): nombre de lignes ajoutées ou supprimées

* Radjenovic *et al,*
“Software fault prediction metrics : A systematic literature review.”, Information and Software Technology, 2013

Contexte

métriques et renommage

Test.php

```
echo "Hello World";
```

version 1
Bob

Test.php

```
echo "Hello " . $_GET['name'];
```

version 2
Joe

Hello.php

```
// Say hello to user.
echo "Hello " . $_GET['name'];
```

version 3
Dan

Renommage

Contexte

métriques et renommage

Test.php

```
echo "Hello World";
```

version 1
Bob

Test.php

```
echo "Hello " . $_GET['name'];
```

version 2
Joe

Hello.php

```
// Say hello to user.
echo "Hello " . $_GET['name'];
```

version 3
Dan

NoD = 1, NoC = 1, CC = 2

Contexte

métriques et renommage

Test.php

```
echo "Hello World";
```

version 1
Bob

NoD = 1, NoC = 1, CC = 1

Test.php

```
echo "Hello " . $_GET['name'];
```

version 2
Joe

NoD = 2, NoC = 2, CC = 1

Hello.php

```
// Say hello to user.
echo "Hello " . $_GET['name'];
```

version 3
Dan

NoD = 3, NoC = 3, CC = 2

Contexte gestionnaires de versions

	Traitement du renommage		
		Automatique	
Outil	Manuel*	Standard	Optionnel
CVS			
Subversion	×		
Mercurial	×		
Git			×

** Kim et al,*
"A field study of refactoring challenges and benefits", Foundations of Software Engineering, 2012.

Analyse des études antérieures

Radjenovic et al, "Software fault prediction metrics : A systematic literature review", Information and Software Technology, 2013.

- Des études et expérimentations pour la prédiction de bugs, qui utilisent les métriques de procédés :

- 11 projets open source

ArgoUML

- 15 projets industriels

Problématique

- Quelle est la quantité de renommage dans les projets ?
- Ce renommage a-t-il un impact réel sur les métriques de procédés ?

Méthodologie corpus

5 projets open-source :

Projet	Language dominant	Taille (LoC)	Nombre de développeurs	URL
Jenkins	Java	200851	454	github.com/jenkinsci/jenkins
JQuery	JavaScript	41656	223	github.com/jquery/jquery
PHPUnit	PHP	21799	152	github.com/sebastianbergmann/phpunit
Pyramid	Python	38726	205	github.com/Pylons/pyramid
Rails	Ruby	181002	2767	github.com/rails/rails

Méthodologie première expérience

- Quantité de renommage
- Localisation

Méthodologie première expérience

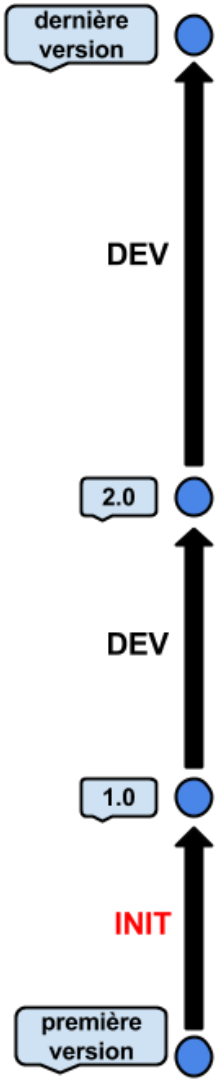

- Quantité de renommage
- Localisation

Méthodologie première expérience

1. Lister les fichiers existant à la fin de la période.

2. Pour chacun de ces fichiers, extraire sa séquence de modifications durant la période en activant la détection de renommage (commande git log -M).

3. Calculer le pourcentage de fichiers %FR qui inclue au moins un renommage.

Méthodologie première expérience

1. Lister les fichiers existant à la fin de la période.

2. Pour chacun de ces fichiers, extraire sa séquence de modifications durant la période en activant la détection de renommage (commande git log -M).

3. Calculer le pourcentage de fichiers %FR qui inclue au moins un renommage.

```
commit 3d87c26845095438b6c946dc4e1029280593fb91
Author: Aaron Patterson <aaron.patterson@gmail.com>
Date:   Fri May 2 11:52:37 2014 -0700

    push up bind params on "simple" subquery calculations
    bind parameters we not being propogated to simple subquery
    calculation calls. This fixes it

 activerecord/lib/active_record/relation/calculations.rb            |    6 ++++--
 activerecord/test/cases/associations/has_many_associations_test.rb |    8 +++++++-
 2 files changed, 11 insertions(+), 3 deletions(-)
```

Méthodologie première expérience

1. Lister les fichiers existant à la fin de la période.

2. Pour chacun de ces fichiers, extraire sa séquence de modifications durant la période en activant la détection de renommage (commande git log -M).

3. Calculer le pourcentage de fichiers %FR qui inclue au moins un renommage.

Méthodologie deuxième expérience

Calculs de **NoD, NoC, CC** sur nos projets.

Pour chaque métriques pour chaque projets on obtient deux listes.

NoD			
sans renommage		avec renommage	
fichiers	valeur	fichier	valeur
A.rb	3	D.rb	5
B.rb	2	C.rb	4
C.rb	2	A.rb	3
D.rb	1	B.rb	2

Méthodologie deuxième expérience

Corrélation de **Spearman** :

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$$

Avec (xi, yi) les rangs données par les deux valeurs de Métriques (Xi, Yi)

Résultats première expérience

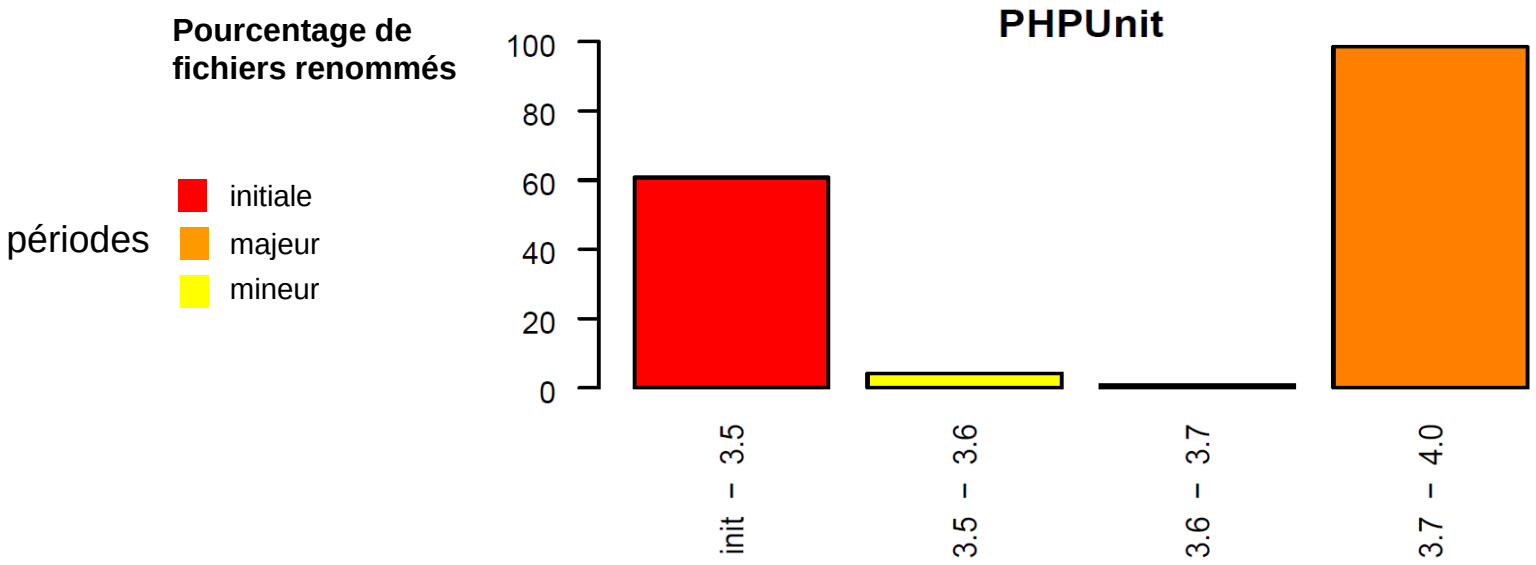

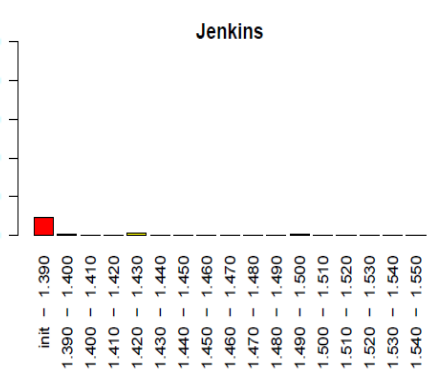

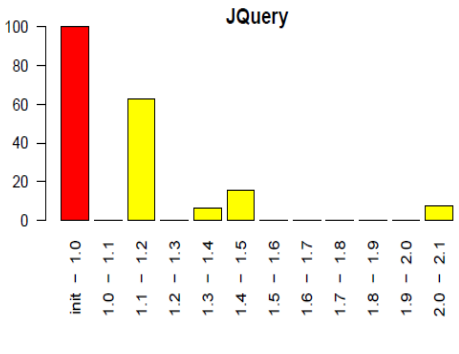

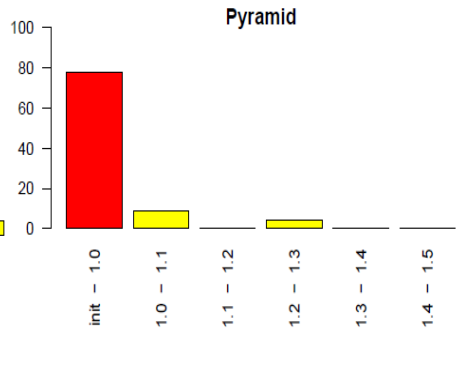

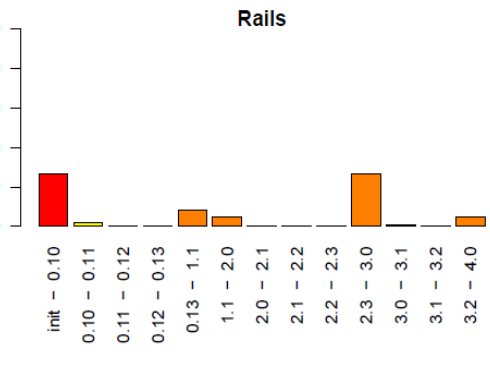

Résultats deuxième expérience

Coefficient de corrélation de Spearman :

		Métriques de procédés		
Période	$\%F_R$	CC	NoD	NoC
Jenkins 1.420 - 1.430	0.86	1	1	1
JQuery 1.1 - 1.2	62.5	0.98	**0.08**	**0.59**
PHPUnit 3.7 - 4.7	98.51	**0.6**	**0.38**	**0.71**
Pyramid 1.0 - 1.1	8.69	0.97	1	1
Rails 2.3.0 - 3.0.0	26.49	0.98	0.96	0.93

Conclusion

Le renommage :

- Jusqu’à 100% des fichiers d’un projet.
- Fausse complétement le calcul des métriques de procédés.

Les recommandations :

- Périodes initiales
- Utiliser un algorithme de détection de renommage, Git à défaut
- Attention au niveau de granularité
- Le renommage dans les prochaines études

Prochaine étapes:

- Evaluer la précision des algorithmes de détection de renommage
- Etude des split et merge d’entités

Annexe A

Analyses des études antérieures

Annexe B

« Origin Analysis* »

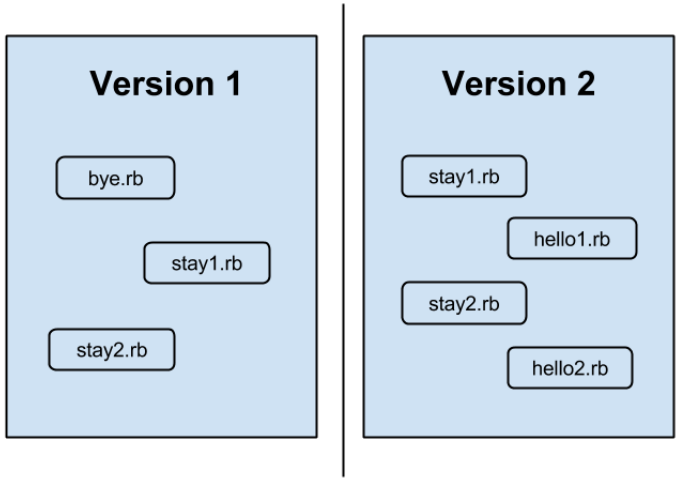

Composants d'un projets lors de deux versions consécutives.
Mise en corrélation des éléments « supprimés » et « créés » pour détecter les renommages potentiels.

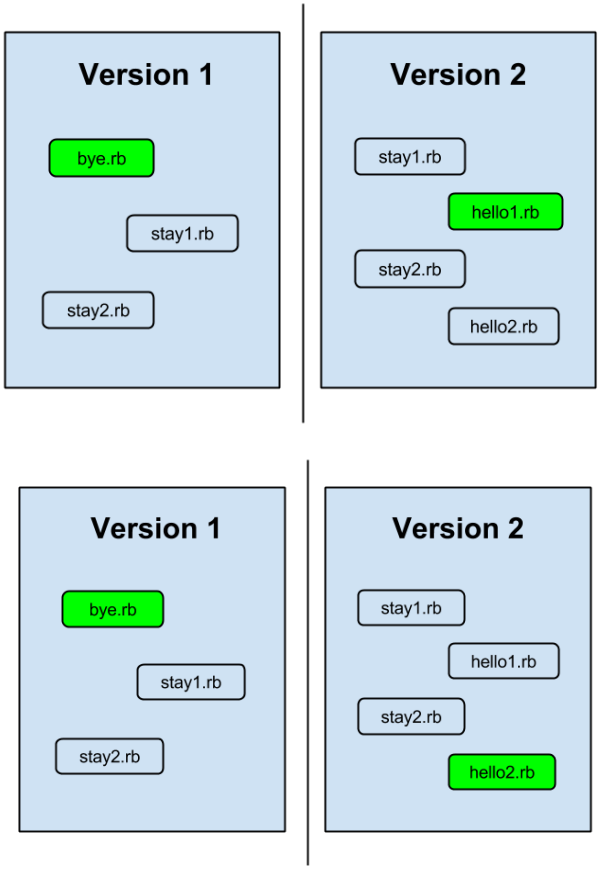

** Godfrey et al. "An integrated approach for studying architectural evolution", International Workshop on Program Comprehension, 2002.*

Annexe C

Corrélation de **Spearman** :

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$$

Avec (xi, yi) les rangs données par les deux valeurs de Métriques (Xi, Yi)

Annexe D

Les algorithme de détection de renommage

G. Antoniol, M. Di Penta, and E. Merlo. “An automatic approach to identify class evolution discontinuities”. In Software Evolution, 2004.

T. Lavoie, F. Khomh, E. Merlo, and Ying Zou. “Inferring repository file structure modifications using nearest-neighbor clone detection”, In Reverse Engineering (WCRE), 2012.

Daniela Steidl, Benjamin Hummel, and Elmar Juergens, “Incremental origin analysis of source code files”. Conference on Mining Software Repositories, 2014.

Michael Godfrey and Qiang Tu. “Tracking structural evolution using origin analysis”. International Workshop on Principles of Software Evolution, IWPSE 2002.